

Wielowymiarowe zmienne losowe (wektory losowe)

- Syt. Eksperyment losowy E, związana z nim przestrzeń próbek S
- n-wymiarowy wektor losowy** \vec{X} to funkcja, która każdemu elementowi s należącemu do zbioru S przyporządkowuje wektor n liczb rzeczywistych $(X_1(s), X_2(s), \dots, X_n(s))$ (n zmiennych losowych),
Np. Losujemy punkt na płaszczyźnie $X_1(s)=x, X_2(s)=y$
- Nie ma związku pomiędzy wymiarem elementu w S (czyli liczbą zmiennych potrzebnych do opisanie wyniku eksperymentu) a wymiarem wektora losowego \vec{X} .
np. $\vec{X} = (X_1, X_2, X_3, X_4)$:
 $X_1(s) = x_a, X_2(s) = y_a, X_3(s) = x_a + y_a, X_4(s) = \text{sign}(x_a)$
- W dalszym ciągu ograniczymy się do $n=2$

RPIS 2013/2014 1

Łączny rozkład prawdopodobieństwa

- Syt. $\vec{Z} = (X, Y)$ $S_{\vec{Z}} = \{(x_i, y_j)\}$ $i = 1, 2, \dots$ $j = 1, 2, \dots$
- Łącznym rozkładem prawdopodobieństwa** nazywamy (dwuargumentową) funkcję, która
 $\forall i, j: P_{X,Y}(x_i, y_j) = P[\{X = x_i\} \cap \{Y = y_j\}] \equiv P[X = x_i, Y = y_j]$
 - Własności:**
 $\forall i, j: P_{X,Y}(x_i, y_j) \geq 0$
 $\sum_i \sum_j P_{X,Y}(x_i, y_j) = 1$
 $P(A) = \sum_{(x_i, y_j) \in A} P_{X,Y}(x_i, y_j)$
 - Łączna dystrybuanta**
 $F_{X,Y}(x, y) = P[X \leq x, Y \leq y] = \sum_{x_i \leq x} \sum_{y_j \leq y} P_{X,Y}(x_i, y_j)$

RPIS 2013/2014 2

Łączna funkcja gęstości prawdopodobieństwa

- Syt. $\vec{Z} = (X, Y)$, X, Y – ciągle zmienne losowe
- Łączną funkcją gęstości prawdopodobieństwa pary (X, Y)** nazywamy funkcję, która wiąże się z prawdopodobieństwem zdarzenia A poprzez:
$$P(A) = \iint_A f_{X,Y}(x, y) dx dy$$
 - Własności:**
 $\forall x, y: f_{X,Y}(x, y) \geq 0$
$$\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx dy = 1$$

$$P(x < X \leq x + dx, y < Y \leq y + dy) = f_{X,Y}(x, y) dx dy$$

RPIS 2013/2014 3

Kowariancja i korelacja zmiennych losowych

- Syt. $Z = g(X, Y)$
$$E(Z) = \begin{cases} \sum_i \sum_j g(x_i, y_j) P_{X,Y}(x_i, y_j) \\ \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f_{X,Y}(x, y) dx dy \end{cases}$$
- Wnioski: 1. $E(aX + bY) = aE(X) + bE(Y)$
- Dla zmiennych niezależnych
2. $E(g_1(X) \cdot g_2(Y)) = E(g_1(X)) \cdot E(g_2(Y))$
w szczególności dla $g_1(X)=X$ i $g_2(Y)=Y$ $E(XY) = E(X) \cdot E(Y)$
- Dla zmiennych zależnych
 $E(XY) \neq E(X) \cdot E(Y)$
$$\text{cov}(X, Y) = E(XY) - E(X) \cdot E(Y)$$

RPIS 2013/2014 4

Kowariancja i korelacja zmiennych losowych

- Wzór $\text{cov}(X, Y) = E(XY) - E(X) \cdot E(Y)$ jest równoważny
$$\begin{aligned} \text{cov}(X, Y) &= E[(X - E(X))(Y - E(Y))] = \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (x - E(X))(y - E(Y)) f_{X,Y}(x, y) dx dy \end{aligned}$$
- Własności:**
 - $\text{cov}(X, X) = \text{var}(X) \geq 0$
 - Kowariancja nie musi być nieujemna.
 - Dla zmiennych niezależnych $\text{cov}(X, Y) = 0$
 - $E(XY)$ nazywamy **korelacją zmiennych X i Y**

RPIS 2013/2014 5

Współczynnik korelacji zmiennych losowych

- Współczynnik korelacji** zmiennych losowych X, Y (unormowana kowariancja) to
$$\rho_{X,Y} \equiv \text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)\text{var}(Y)}}$$
- Własności:**
 - Współczynnik korelacji jest bezwymiarowy.
 - $-1 \leq \rho_{X,Y} \leq 1$
 - Współczynnik korelacji jest miarą zależności liniowej**
$$\begin{aligned} \rho_{X,Y} &= 1 \quad \text{dla } Y = aX + b \quad a > 0 \\ \rho_{X,Y} &= -1 \quad \text{dla } Y = aX + b \quad a < 0 \end{aligned}$$

RPIS 2013/2014 6

Współczynnik korelacji zmiennych losowych

- Własności:
 - Dla X, Y niezależnych $\rho_{XY}=0$.
 - Jeżeli $\rho_{XY}=0$ to zmienne X i Y nie muszą być niezależne; nazywamy je wtedy **nieskorelowanymi**.
Ważny wyjątek: jeżeli X i Y mają rozkłady normalne i $\rho_{XY}=0$ to zmienne X i Y są niezależne.
 - Jeżeli $\rho_{XY} \neq 0$ to zmienne X i Y nie są niezależne.

Macierz kowariancji

$$K_{X,Y} = \begin{pmatrix} \text{var}(X) & \text{cov}(X,Y) \\ \text{cov}(Y,X) & \text{var}(Y) \end{pmatrix}$$

Jest symetryczna, bo $\text{cov}(X,Y) = \text{cov}(Y,X)$.

$$V_N = \frac{2}{N} \frac{\pi^{N/2}}{\Gamma(N/2)}$$

- Korelacja jako narzędzie testowania generatorów liczb pseudolosowych ($\rho_{XY}=0$), zadania kontrolne, np. N-wymiarowa kula o $R=1$.

RPIS 2013/2014 7

Twierdzenia graniczne

Nierówność Czebyszewa

Zał. Zmienna losowa X ma wartości nieujemne

$$\forall a > 0: P(X \geq a) \leq \frac{E(X)}{a}$$

Dowód:

$$\begin{aligned} E(X) &= \sum x_k P_X(x_k) = \sum_{x_k < a} x_k P_X(x_k) + \sum_{x_k \geq a} x_k P_X(x_k) \geq \\ &\geq \sum_{x_k \geq a} x_k P_X(x_k) \geq \sum_{x_k \geq a} a P_X(x_k) = a \sum_{x_k \geq a} P_X(x_k) = a P_X(X \geq a) \\ \Rightarrow E(X) &\geq a P_X(X \geq a) \Rightarrow P_X(X \geq a) \leq \frac{E(X)}{a} \end{aligned}$$

RPIS 2013/2014 8

Twierdzenia graniczne

Nierówność Czebyszewa-Bienayme

Zał. Dla zmiennej losowej X istnieje $E(X)=\mu$ i $\text{var}(X)=\sigma^2 < \infty$

$$\forall a > 0: P(|X - \mu| \geq a) \leq \frac{\sigma^2}{a^2}$$

Dowód:

$$(X - \mu)^2 \geq 0 \Rightarrow (\text{z nierówności Czebyszewa})$$

$$P((X - \mu)^2 \geq a^2) \leq \frac{E((X - \mu)^2)}{a^2}$$

$$P(|X - \mu| \geq a) \leq \frac{\text{var}(X)}{a^2} = \frac{\sigma^2}{a^2}$$

Oba powyższe twierdzenia nie zależą od rozkładu.

Przykład: losowanie kul

RPIS 2013/2014 9

Twierdzenia graniczne

Prawo wielkich liczb Bernoulliego (słabe)

Zał. S_n – liczba sukcesów (o prawdopodobieństwie p) w n próbach

$$\forall \varepsilon > 0: \lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - p\right| \leq \varepsilon\right) = 1$$

Dowód (rozpatrujemy zdarzenie przeciwne):

$$X \equiv \frac{S_n}{n} \Rightarrow E(X) = E\left(\frac{S_n}{n}\right) = \frac{1}{n} E(S_n) = \frac{1}{n} np = p$$

$$\text{var}(X) = \text{var}\left(\frac{S_n}{n}\right) = \frac{1}{n^2} \text{var}(S_n) = \frac{1}{n^2} np(1-p) = \frac{p(1-p)}{n}$$

(z nierówności Czebyszewa-Bienayme)

$$P(|X - p| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2} \Rightarrow P\left(\left|\frac{S_n}{n} - p\right| \geq \varepsilon\right) \leq \frac{p(1-p)}{n\varepsilon^2} \xrightarrow{\lim_{n \rightarrow \infty}} 0$$

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - p\right| > \varepsilon\right) \leq 0 \Rightarrow \lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - p\right| \geq \varepsilon\right) = 0 \Rightarrow \lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - p\right| \leq \varepsilon\right) = 1$$

RPIS 2013/2014 10

Twierdzenia graniczne

Prawo wielkich liczb Bernoulliego (słabe)

Zał. S_n – liczba sukcesów (o prawdopodobieństwie p) w n próbach

$$\forall \varepsilon > 0: \lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - p\right| \leq \varepsilon\right) = 1$$

- Słabe prawo „Jest bardzo prawdopodobne, że częstotliwość będzie równa p dla ustalonego, dużego n ”.
- Jest to „zbieżność według prawdopodobieństwa”

Mocne prawo wielkich liczb Bernoulliego

Zał. S_n – liczba sukcesów (o prawdopodobieństwie p) w n próbach

$$\forall \varepsilon > 0: P\left(\lim_{n \rightarrow \infty} \left|\frac{S_n}{n} - p\right| \leq \varepsilon\right) = 1 \quad P\left(\lim_{n \rightarrow \infty} \frac{S_n}{n} = p\right) = 1$$

- Mocne prawo „Częstotliwość musi być w pobliżu p gdy n rośnie”.
- Jest to „zbieżność prawie na pewno”

RPIS 2013/2014 11

Całkowanie metodą Monte Carlo

Mocne prawo wielkich liczb Kołmogorowa

- X_n – ciąg niezależnych zmiennych losowych o jednakowym rozkładzie, $E(|X_1|)$ jest skończona, $S_n = X_1 + X_2 + \dots + X_n$

$$P\left(\lim_{n \rightarrow \infty} \frac{S_n}{n} = E(X_1)\right) = 1$$

- Uzasadnia to definicję częstotliwościową prawdopodobieństwa
- Problem: całkowanie numeryczne $f(x)$ w przedziale (a, b)

$$I = \int_a^b f(x) dx = \int_a^b f(x) \frac{g(x)}{g(x)} dx = E\left(\frac{f(x)}{g(x)}\right) = \frac{1}{n} \sum_{i=1}^n \frac{f(x_i)}{g(x_i)}$$

$$g(x) > 0 \quad \int_a^b g(x) dx = 1$$

MPWL

RPIS 2013/2014 12

Całkowanie metodą Monte Carlo

- Zatem
$$I = \int_a^b f(x) dx = \frac{1}{n} \sum_{i=1}^n \frac{f(x_i)}{g(x_i)}$$
- Niech $g(x_i)$ – jednostajna na przedziale (a,b) .

$$\int_a^b f(x) dx = \frac{(b-a)}{n} \sum_{i=1}^n f(x_i)$$
- Zał. Znamy $\text{var}(f(x_i))$. Wtedy $\text{var}(I) = \text{var}(f(x_i))/n$
- Poprawę jakości można uzyskać min przez:
 - dobierając $g(x)$ jako podobną do $f(x)$
 - losowanie warstwowe (rozbijamy całkę na przedziały, gdzie $f(x)$ jest w przybliżeniu stała
 - metodą zmiennych kontrolnych – $h(x)$ podobne do $f(x)$ ale o znanej całce.

$$\int_a^b f(x) dx = \int_a^b (f(x) - h(x)) dx + \int_a^b h(x) dx$$

RPiS 2013/2014 13

Całkowanie metodą Monte Carlo

- Całkowanie metodą Monte Carlo stosujemy do całek wielokrotnych.
- Np. całka dziesięciokrotna z $f(x_1, x_2, \dots, x_{10})$, przy czym jednokrotne wyliczenie $f(x_1, x_2, \dots, x_{10})$ zajmuje 0.0001 sekundy.
- Metoda prostokątów wymaga N^{10} wyliczeń funkcji
 Dla $N=10$ czas wykonania programu $10^{10}/10^4=10^6$ sekund (około 12 dob)
- Metoda Monte Carlo
 Niepewność $\sigma(f(x_i)) n^{-0.5}$
 Dla $\sigma(f(x_i))=0.01f(x_i)$ (1%) i $n=10^6$ mamy
 dokładność rzędu 0.00001 (0.001%)
 czas wykonania programu $10^6/10^4=100$ sekund

RPiS 2013/2014 14

Twierdzenia graniczne

- Centralne twierdzenie graniczne**
 Zał. Zmienne losowe X_1, X_2, \dots, X_n są niezależnymi zmiennymi o tej samej funkcji gęstości prawdopodobieństwa z $E(X_i)=\mu$ i $\text{var}(X_i)=\sigma^2>0$

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{X_1 + \dots + X_n - n\mu}{\sigma\sqrt{n}}\right| \leq a\right) = F_{N(0,1)}(a) - F_{N(0,1)}(-a)$$

gdzie $F_{N(0,1)}(a)$ oznacza dystrybuantę rozkładu $N(0,1)$.

- Wniosek: zmienna będąca sumą innych zmiennych losowych dąży do rozkładu $N(n\mu, n\sigma^2)$.
- Ogólniejsza wersja twierdzenia mówi, że suma zmiennych o dowolnych funkcjach gęstości o dodatnich wariancjach, w której żaden ze składników nie dominuje, ma rozkład normalny.

RPiS 2013/2014 15