1. Czym jest baza danych?

Odp.:

- zorganizowanym zbiorem danych zapisanych w ściśle określony sposób w strukturach odpowiadających przyjętemu modelowi danych,
- zbiorem reprezentującym pewien fragment świata rzeczywistego, zwany obszarem analizy,
- zbiorem zaprojektowanym, zbudowanym i utrzymywanym dla określonej grupy użytkowników i dla określonego sposobu korzystania z tych danych

2. Z czego składają się dane w bazie?

Odp.: Z jednostek elementarnych.

3. Czym są dane strukturalne?

Odp.: Są to liczby, napisy, daty etc.

4. Czym są dane multimedialne?

Odp.:

- Utwory muzyczne,
- audycje lub inne twory dźwiękowe,
- rysunki techniczne,
- fotografie lub inne obrazy stałe,
- dokumenty języka naturalnego,
- animacje,
- nagrania wideo,
- filmy z dźwiękiem i napisami,
- mapy cyfrowe.

5. Czym są jednostki semistrukturalne?

Odp.: Jednostki danych, które nie mają stałej struktury lecz zawierają informacje o swojej strukturze (np. dokumenty XML).

6. Czym są jednostki niestrukturalne?

Odp.: Jednostki, które nie mają stałej struktury i nie zawierają informacji o swojej strukturze (np. rysunek techniczny).

7. Czym jest informacja?

Odp.: Informacja, to dane do których zostało przypisane znaczenie, to dane zinterpretowane! Informacja ma zawsze charakter subiektywny i jest związana z kontekstem.

Różne dane mogą stanowić tę samą informację i na odwrót: te same dane mogą dostarczać różnych informacji.

- 8. Jakie są rodzaje baz danych? Odp.:
 - Active database
 - Cloud database
 - Graph database
 - Spatial database
 - End-user database
 - Unstructured-data database
 - Federated database and multi-database

- Knowledge base
- Operational database
- Real-time database
- Embedded database
- In-memory database
- Document-oriented database
- Data warehouse
- Parallel database
- Hypertext database
- Temporal database
- Distributed database
- Hypermedia databases
- 9. Opisz strukturę tradycyjnej (atrybutowej) bazy danych

Odp.: Jest reprezentowana w schemacie, a wszystkie zapytania odwołują się do tej sztywnej struktury. W przypadku baz relacyjnych są to nazwy tabel, nazwy, typy, własności i zakresy wartości atrybutów, oraz związki referencyjne między atrybutami.

10. Czym jest multimedialna baza danych?

Odp.: Multimedialne bazy danych to systemy, w których informacja przechowywana jest w węzłach różnego rodzaju mediów (np.teksty, dźwięki, filmy, obrazy) połączonych za pomocą tzw. "wiązań asocjacyjnych" i które oferują użytkownikom zarówno możliwość nawigacji oraz udostępniania tych informacji, jak i korzystanie z tzw. "urządzeń wyszukiwawczych", które przetwarzają dane multimedialne.

11. Czym odróżnia się baza z multimedialną zawartością od multimedialnej bazy danych? Odp.: Wyszukiwanie zorganizowane jest tradycyjnie, tj. gdy obiektami przeszukiwanymi są opisy zdjęć, filmów, książek czy płyt wpisane w sztywną strukturę (schemat bazy). Multimedialną zawartość da się "upchnąć" do popularnych relacyjnych bądź obiektoworelacyjnych baz danych w postaci obiektów typu BLOB. Wtedy do każdego takiego obiektu dodaje się "nagłówek", tj. opis zawartości obiektu binarnego, a wszelkie operacje wyszukiwania mogą uwzględniać wyłącznie zawartość tych "nagłówków".

12. Czym jest aplikacja bazodanowa?

Odp.: Aplikacja bazodanowa to każdy system z bazą danych wykonany przy użyciu technologii informatycznej.

13. Czym jest kartoteka?

Odp.: Spis obiektów jednego typu o ustalonej strukturze, spis w postaci listy atrybutów, umożliwiający klasyfikację obiektów według kategorii lub wybór obiektów według określonych kryteriów wyszukiwania.

14. Czym jest SZBD?

Odp.: Jest to oprogramowanie do tworzenia baz i zarządzania bazami danych.

15. Czym jest motor/silnik bazodanowy?

Odp.: Komponent SZBD przeznaczony do wykonywania operacji CRUD (od ang. create, read, update, delete) na bazie danych.
W ramach danego SZBD możemy mieć do wyboru kilka motorów, np. w MySQL mamy motory InnoDB, MyISAM, Memory, Archive, Blackhole i in.).

16. Co składa się na serwer bazodanowy?

Odp.: Komponenty tworzące jądro SZBD i świadczące usługi na rzecz innych programów.

17. Podaj przykłady SZBD.

Odp.: PostgreSQL, MySQL, SQLite, Firebird.

18. Wymień własności SZBD.

Odp.:

- możliwość bezpiecznego przechowywania przez długi czas danych
- istnienie mechanizmów "masowego" wprowadzania danych
- zapewnienie bezpieczeństwa danych
- efektywny dostęp do danych
- sterowanie współbieżnością
- trójwarstwowa struktura (jądro, interfejs i narzędzia)
- możliwość tworzenia nowej bazy danych, tzn. określenia jej schematu i więzów integralności za pomocą jakiegoś języka definiowania danych

19. Wymień zalety podejścia bazodanowego.

Odp.:

- niezależność między danymi a programami
- ukrywanie szczegółów dotyczących sposobu przechowywania danych w pamięci fizycznej
- przechowywanie metadanych
- dostarczanie wielu widoków (perspektyw) danych dla różnych grup użytkowników
- zapewnienie integralności danych
- współdzielenie danych i współbieżne transakcje wielu użytkowników
- wysoka niezawodność i bezpieczeństwo

20. Na czym polega specyfikacja wymagań?

Odp.: Specyfikacja wymagań jest pomocą w zrozumieniu obszaru analizy i poprawnym zaprojektowaniu bazy. Przyjmuje ona (w naszym podejściu) postać tekstu opisującego dane, ich przetwarzanie i użytkowników. W specyfikacji tej powinny się znaleźć także szacunki dotyczące wielkości bazy, liczby użytkowników, intensywności korzystania z danych, używanego sprzętu i oprogramowania. Specyfikacja wymagań stanowi punkt odniesienia całego projektu. Jest ona ważna także dlatego, że w trakcie wykonywania projektu zmienić może się zarówno obszar analizy, jak i wymagania przyszłych użytkowników.

21. Czym jest encja?

Odp.: Encja to coś:

- co istnieje niezależnie i jest jednoznacznie identyfikowane, rozpoznawalne
- czym informacje mają być przechowywane w bazie
- co występuje (potencjalnie) w wielu egzemplarzach
- czemu łatwo nadać nazwę pospolitą (a nie własną)!

22. Czym jest typ encji?

Odp.: Typ encji to "pojemnik" na encje, które są podobne do siebie w tym sensie, że ich charakterystyki (czyli to, co ma być pamiętane w bazie) mają taką samą strukturę. Typom encji nadajemy nazwy pospolite w formie liczby pojedynczej.

23. Czym jest związek unarny?

Odp.: Związek encji tego samego typu (np. PRACOWNIK podlega PRACOWNIK)

24. Czym jest związek binarny?

Odp.: Związek encji dwóch różnych typów (np. KLIENT kupuje BILET)

25. Czym jest stopień związku encji?

Odp.: Ilość encji w związku.

wypisuje (LEKARZ, PACJENT, RECEPTA) – związek 3-go stopnia miedzy 3 różnymi typami encji sprzedaje (PODMIOT, PODMIOT, NIERUCHOMOŚĆ) – zw. 3-go stopnia miedzy 2 typami encji

26. Podaj trzy rodzaje związków binarnych.

Odp.: 1:1, 1:N, N:M

27. Na czym polega pełny udział encji w związku?

Odp.: Każda encja danego typu musi wchodzić w taki związek.

28. Na czym polega częściowy udział encji w związku?

Odp.: Udział częściowy oznacza dowolność: niektóre encje wchodzą w ten związek, inne nie.

29. Na czym polega warunek strukturalny udziału encji w związku?

Odp.: Warunek taki ma postać (k,n) i oznacza, że co najmniej k encji i co najwyżej n encji danego typu wchodzi w ten związek.

Przykładem warunku strukturalnego jest warunek (2,3) udziału encji typu doktorant w związku z encjami typu recenzent. Oznacza on, że każdy doktorant musi mieć dwie recenzje swojej rozprawy, ale zdarza się, że ma 3 recenzje. Większej liczby recenzji nie dopuszcza się.

30. Czym są atrybuty?

Odp.: Wybrane przez analityka istotne własności encji danego typu, tworzące strukturę drzewa, którego korzeniem jest dana encja. Charakterystykę konkretnej encji tworzy układ wartości atrybutów.

Związki encji mogą również posiadać tego rodzaju charakterystyki: układ wartości atrybutów.

Atrybuty typów encji i związków encji mogą być atrybutami złożonymi bądź elementarnymi (liście drzewa). Dla każdego atrybutu elementarnego trzeba określić dziedzinę wartości tego atrybutu.

Atrybuty mogą być jednowartościowe albo wielowartościowe.

Ponadto wyróżnia się atrybuty wyliczeniowe (ich wartości są wyliczane z wartości innych atrybutów).

31. Czym jest diagram związków encji?

Odp.: Diagram związków encji jest grafem reprezentującym strukturę danych. Wierzchołki tego grafu reprezentują typy encji, związki i atrybuty, a dla ich odróżniania używa się odpowiednio kształtów prostokąta, rombu i elipsy. Krawędzie jednego typu wiążą prostokąty lub romby z owalami. Krawędzie drugiego typu wiążą prostokąty z rombami. Niektóre z krawędzi drugiego typu mogą być etykietowane.

32. Co charakteryzuje rozszerzenia ERD?

Odp.:

- słabe typy encji i związki identyfikujące
- specjalizacja i podklasy
- związki "isa"
- kategoryzacja

33. Czym są tabele Codda?

Odp.: Tabela jest tutaj czymś podobnym do matematycznej relacji, a zarazem do zwykłej tabeli złożonej z nagłówka, kolumn i wierszy.

W nagłówku występuje nazwa tabeli oraz nazwy kolumn.

W polach wierszy występują wartości atrybutów.

W tabeli Codda nie jest ustalony ani porządek kolumn, aniporządek wierszy! Tabela pusta zawiera tylko nagłówek!

34. Wymień kryteria Codda.

Odp.:

- Informacje są reprezentowane w tabelach.
- Dane są dostępne przez podanie nazwy tabeli, wartości klucza głównego i nazwy kolumny.
- Wartości null są traktowane w jednolity sposób jako "brakujące informacje".
 Nie mogą być traktowane jako puste łańcuchy znaków, puste miejsca, czy zera.
- Metadane (dane dotyczące bazy danych) są umieszczone w bazie danych dokładnie tak, jak zwykłe dane.
- Język obsługi danych ma możliwość definiowania danych, perspektyw i więzów integralności, przeprowadzenia autoryzacji, obsługi transakcji i manipulacji danymi.
- Perspektywy reagują na zmiany swoich tabel bazowych. Odwrotnie, zmiana w perspektywie powoduje automatycznie zmianę w tabeli bazowej.
- Istnieją pojedyncze operacje pozwalające na wyszukanie, wstawienie, uaktualnienie i usunięcie danych.

- Operacje użytkownika są logicznie oddzielone od fizycznych danych i metod dostępu do danych.
- Operacje użytkownika pozwalają na zmianę struktury bazy bez konieczności tworzenia od nowa bazy czy aplikacji ją obsługującej.
- Więzy integralności są umieszczone i dostępne w metadanych, a nie w programie obsługi bazy danych.
- Język manipulacji danymi powinien działać bez względu na to, jak i gdzie są rozmieszczone fizyczne dane oraz nie powinien wymagać żadnych zmian, gdy fizyczne dane są centralizowane lub rozpraszane.
- Operacje na pojedynczych wierszach tabel przeprowadzane w systemie podlegają tym samym zasadom i więzom, co operacje na zbiorach danych.

35. Podaj definicję relacyjnej bazy danych.

Odp.: Relacyjna baza danych jest zbiorem danych tworzących tabele (w sensie Codda) i spełniających określone warunki integralności danych.

Tabela Codda reprezentuje relację. Kolumny i wiersze tabel odpowiadają atrybutom i krotkom relacji.

Kolumny i wiersze nie są uporządkowane!

Nagłówek tabeli odpowiada schematowi relacji.

36. Czym jest relacja rozpięta na schemacie?

Odp.: Dowolny podzbiór iloczynu kartezjańskiego $D1 \times D2 \times ... \times Dn$ nazywamy relacją rozpiętą na schemacie F(A1, A2, ... An). Gdzie $\{A1, A2, ... An\}$ to zbiór atrybutów, a z każdym atrybutem Ai związana będzie dziedzina Di wartości tego atrybutu.

37. Podaj definicję schematu relacyjnej bazy danych.

Odp.: Schematem relacyjnej bazy danych nazywamy zbiór pustych tabel oraz więzów integralności danych, które można do tych tabel wprowadzić.

38. Konwencje schematów relacyjnych baz danych.

Odp.:

39. Na czym polega przejście z ERD do schematu relacyjnej bazy danych?

Odp.: Przejście od ERD do schematu relacyjnej bazy danych polega na zastąpieniu wszystkich typów encji i niektórych powiązań między typami encji – schematami relacji i łącznikami. SLAJDY 64 - 94

40. Co to jest wartość modalna?

Odp.: Wartość modalna to wartość najczęściej pojawiająca się w zbiorze (jeśli są takie dwie wartości, to mówimy że rozkład jest dwumodalny, podobnie trzymodalny etc.).

41. Czym jest mediana?

Odp.: Jest to wartość, dla której jest dokładnie tyle samo elementów o wartościach od niej niższych, co elementów o wartościach od niej wyższych. Jeśli taka wartość istnieje w zbiorze danych to nazywamy ją medianą statystyczną, jeżeli nie, to oblicza się medianę finansową.

Zbiór danych dzieli się wtedy na dwa równoliczne, tak by elementy pierwszego były mniejsze od elementów drugiego, następnie oblicza się średnią między maksimum pierwszego i minimum drugiego. Inne nazwy: wartość środkowa, wartość przeciętna.

Z mediana statystyczna jest problem, gdy wartości środkowych jest kilka (wskazany wyżej

Z medianą statystyczną jest problem, gdy wartości środkowych jest kilka (wskazany wyżej podział jest wówczas niemożliwy).

42. Czym są kwartyle?

Odp.: Kwartyle dzielą wszystkie obserwacje na cztery równe co do ilości grupy .Kwartyl pierwszy (Q1) dzieli obserwacje w stosunku 25% do 75%, co oznacza, że 25% obserwacji jest niższa bądź równa wartości Q1, a 75% obserwacji jest równa bądź większa niż Q1. Kwartyl drugi (Q2), inaczej zwany medianą(!), dzieli obserwacje na dwie części w stosunku 50% do 50%.

Kwartyl trzeci (Q3) dzieli obserwacje w stosunku 75% do 25%, co oznacza, że 75% obserwacji jest niższa bądź równa wartości Q3, a 25% obserwacji jest równa bądź większa niż Q3. Odchylenie ćwiartkowe (Q), to połowa różnicy między trzecim a pierwszym kwartylem.

43. Czym są kwantyle?

Odp.: Kwantylem rzędu p z przedziału (0,1) jest taka wartość xp zmiennej losowej, że wartości ≤xp są przyjmowane z prawdopodobieństwem co najmniej p, a wartości ≥xp są przyjmowane z prawdopodobieństwem co najmniej 1–p.

Kwantyl rzędu ½ to inaczej mediana.

Kwantyle rzędu ¼, 2/4, 3/4 to kwartyle

Kwantyle rzędu ⅓, ⅔, ⅓, ⅓ to kwintyle.

Kwantyle rzędu 1/10, 2/10, ... to decyle.

44. Omów tabele pomocnicze.

Odp.: Tabele pomocnicze nie są częścią modelu danych, więc nie powinny pojawiać się na etapie projektowania koncepcyjnego. Wyróżnimy dwa rodzaje takich tabel: tabele słownikowe i tabele funkcyjne.

45. Czym jest tabela funkcyjna?

Odp.: Tabela funkcyjna jest sposobem zdefiniowania funkcji i jest wykorzystywana do wykonywania zapytań. Często tworzoną tabelą funkcyjną jest kalendarz. Jest tak m. in. dlatego, że daty świąt są bardzo nieregularne (np. wyznaczanie świąt ruchomych, takich jak Wielkanoc czy Ramadan, przy użyciu funkcji byłoby bardzo trudne). Wielkość kalendarza na 20 lat to tylko około 7000 wierszy, czyli bardzo mała tabela. Tabelę taką zapełniamy danymi przygotowanymi w arkuszu kalkulacyjnych bądź pobranymi z Internetu i zabraniamy modyfikacji tych danych użytkownikom bazy (z wyłączeniem administratora danych, bo przecież mogą następować zmiany ustawowe regulujące liczbę i terminy świąt, terminy wakacji szkolnych itp.).

46. Czym jest tabela słownikowa?

Odp.: Rozważmy dwa przypadki tabel słownikowych: listę nazw województw oraz listę nazw państw świata. Obie listy powinny być używane zawsze wtedy, gdy użytkownik bazy danych będzie mógł wprowadzać te nazwy jako dane. Wprowadzanie to powinno być zawsze (w tego rodzaju przypadkach) ograniczone do wyboru elementu z listy!... Sprawa nie jest jednak prosta (por. alfabetyczny wykaz krajów...).

47. Daty i czasy wg. ISO 860

Odp.:

- Data kalendarzowa ma dwa formaty. W formacie rozszerzonym to YYYYMMDD, w formacie podstawowym to YYYYMMDD kalendarza gregoriańskiego.
 Rok 0001 to 1 rok n.e., a 0000 to 1 rok p.n.e. (1 B.C.).
- Data porządkowa ma formaty YYYYDDD lub YYYYDDD, gdzie DDD to kolejny dzień w roku w formacie 3cyfrowym.
 - Np. 3 lutego to zawsze 034, ale 31 grudnia to 365 lub 366.
- Data tygodniowa ma formaty YYYYWwwD, gdzie W to symbol stały, ww to numer tygodnia w roku, D to numer dnia tygodnia, np. dziś to 2013W472 (47 tydzień roku, wtorek).
- Czas ma również dwa formaty. Formaty rozszerzone czasu to hh:mm:ss, hh:mm.
 Formaty podstawowe to hhmmss, hhmm i hh. Po liczbie sekund może wystapić część ułamkowa.
 - Uwaga: północ w Sylwestra to 24:00 dnia 31 grudnia albo 00:00 dnia 1 stycznia.
- Czas uniwersalny UTC oznacza się literą Z na końcu. Czas lokalny przez wskazanie przesunięcia, np. w zimie w Polsce godzina 10:40 to 10:40+01 lub 10:40+01:00 i jest równa 9:40Z.
- Łączny zapis daty i czasu uzyskamy wstawiając między te dane separator T lub spację: 2013:11:19T10:40.85+01:00

48. Daty i czas w SQL

Odp.:

- typy danych związane z datą i czasem: DATE, TIME, TIMESTAMP
- typy danych z odcinkami czasu: INTERVAL.
- Interwały typu rokmiesiąc mają domyślną precyzję obejmującą pola YEAR i MONTH.
- Interwały typu dzieńczas mają precyzję DAY, HOUR, MINUTE i SECOND (z częścią ułamkową).
- Standard obejmuje też pełny zestaw operatorów dla czasowych typów danych (w różnych produktach pełna składnia i funkcjonalność nie jest implementowana).
- Koniec czasu to w SQL data 9999-12-31.
- DATE ma zakres od 1000-01-01 do 9999-12-31 oraz 0000-00-00.
- DATETIME od 1000-01-01 00:00:00 do 9999-12-31 23:59:59 oraz wartość "zero"
- TIMESTAMP podobnie jak DATETIME ale jest zapisywany jako liczba sekund od początku zakresu. Nie przyjmuje wartości początku przedziału, bo byłaby to wartość 0 sekund. Wartośc ta jest interpretowana jako 0000-00-00 00:00:00.
- TIME ma zakres od 838:59:59 do 838:59:59 (w tym zero).

- YEAR ma zakres od 1901 do 2155 oraz 0000 (ale w formacie 2cyfrowym od 1970 do 2069, więc 00 to 2000)
- Standard SQL nie obsługuje czasowych baz danych (temporalnych), bo:
 - o nie uwzględnia tabel zmiennych w czasie,
 - kocepcji bieżących lub sekwencyjnych ograniczeń, zapytań, modyfikacji i widoków,
 - o rozróżnienia między czasem ważnym a czasem transakcji.

49. Algebra relacji

Odp.:

zob. http://wazniak.mimuw.edu.pl/, wykład 2(1) zob. Garcia-Molina, Ullman, Widom...: rozdział 5

50. Przechowywanie danych

Odp.: Wykorzystanie systemu plików, dostępu do plików za pośrednictwem systemu operacyjnego i proste rozwiązanie polegające na przechowywaniu każdej tabeli w jednym pliku, informacji o strukturze tabeli w drugim pliku, a wyników operacji na tabelach w kolejnym pliku - nie nadaje się do stosowania w bazach danych.

Oto kilka powodów:

- modyfikacja jednego wiersza może spowodować konieczność przesunięcia wszystkich wierszy w pliku,
- przeszukiwanie może być bardzo kosztowne, bo np. warunek zapytania będzie sprawdzany dla każdego wiersza,
- działanie takie, jak złączenie dwóch tabel będzie realizowane jako utworzenie nowej tabeli zawierającej złączone wiersze,
- wszystkie dane będą cały czas przechowywane w plikach na urządzeniu pamięci zewnętrznej,
- użytkownicy nie będą mogli jednocześnie modyfikować tej samej tabeli (tego samego pliku),
- w wyniku awarii urządzenia można utracić dane bądź wyniki operacji na danych.

W rezultacie nawet bardzo proste operacje wymagałyby nieustannego odczytywania i zapisywania zwykle bardzo dużych plików (plików, które nie mieszczą się w pamięci operacyjnej). System zarządzania bazami danych musi wykorzystywać hierarchię pamięci i stosować różne strategie prowadzące do zwiększania wydajności.

51. Na czym polega algorytm windy?

Odp.: Głowice dysku przesuwają się w kierunku od najbardziej wewnętrznego cylindra do najbardziej zewnętrznego i z powrotem. Gdy osiągną cylinder, którego dotyczy żądanie, wykonują żądane zapisy i odczyty, i przesuwają się dalej. Gdy osiągną położenie dla którego nie ma już żądań dla dalszych cylindrów, to zatrzymują się i rozpoczynają ruch w przeciwnym kierunku.

52. Z czego składa się schemat bazy danych?

Odp.: Schemat bazy danych składa się ze schematów relacji i więzów integralności. Każdy schemat relacji ma atrybuty. Atrybuty posiadają znaczenia związane z rzeczywistością, której strukturę informacji odzwierciedlono w schemacie.

53. Czym jest relacja opartą na schemacie?

Odp.: Jest to konkretny zbiór krotek zgodnych ze strukturą i spełniający przyjęte więzy integralności. Każdą relację opartą na schemacie interpretuje się jako zbiór zdań lub faktów opisujących obszar analizy.

54. Do czego prowadzą błędy projektowe bazy?

Odp.: Błędy te prowadzą do niepotrzebnego zwiększenia koniecznej do przechowywania danych przestrzeni pamięciowej i powoduje m.in. anomalie wstawiania, anomalie usuwania i anomalie modyfikowania.

55. Jak należy zachować się w przypadku występowania anomalii?

Odp.: W razie występowania w schematach pewnych anomalii (wstawiania, usuwania, modyfikowania) należy je dokładnie opisać i zapewnić, by procedury aktualizacji danych działały, mimo tych anomalii, poprawnie.

56. Do czego prowadzi występowanie wartości NULL w wielu krotkach?
Odp.: Prowadzi to do zwiększenie przestrzeni pamięciowej oraz do trudności interpretacyjnych. Wartości puste mogą występować tylko w sytuacjach wyjątkowych i trzeba zadbać o to, by były zawsze właściwie interpretowane.

57. Podaj 3 często stosowane interpretacje wartości pustej.

Odp.:

- Atrybut nie ma zastosowania
- Wartość atrybutu nie jest znana
- Wartość atrybutu jest znana, ale jest nieobecna
- 58. Dlaczego należy unikać schematów, w których występują pasujące do siebie atrybuty, nie tworzące par (klucz główny, klucz obcy)?

Odp.: Złączenia naturalne wykonane po takich atrybutach zwykle prowadzą do powstawania tzw. fałszywych krotek, tj. informacji, które nie odpowiadają opisywanej rzeczywistości.

59. Co należy zrobić aby atrybuty były właściwie pogrupowane w schematy, schematy te były łatwe do interpretacji w obszarze analizy i nie pojawiały się inne problemy?

Odp.: Oprócz starannie wykonanego i przemyślanego diagramu, oraz poprawnego mapowania na schemat relacyjnej bazy trzeba jeszcze przeprowadzić proces NORMALIZACJI.

60. Czym jest relacja uniwersalna schematu?

Odp.: Są to wszystkie atrybuty schematu relacyjnej bazy danych (nazwane tak dla ułatwienia prezentacji pewnych problemów teoretycznych).

$$R = \{ A_1, A_2, ... A_n \}$$

61. Czym jest zależność funkcyjna?

Odp.: to wiązanie integralności między atrybutami:

 $X \rightarrow A$, gdzie $X \subset R$ i $A \in R$,

które oznacza, że dla dowolnych krotek stanowiących relację r(R) jeżeli:

$$t_1[X] = t_2[X]$$
 to $t_1[A] = t_2[A]$.

Innymi słowy , wartości atrybutów tworzących zbiór X krotki t relacji r(R) jednoznacznie determinują wartość tej krotki dla atrybutu A.

Zależność funkcyjna jest własnością schematu R i ma być spełniona przez wszystkie relacje r(R) rozpięte na tym schemacie.

Dla uproszczenia zapisów przymujemy, że

 $X \rightarrow Y$, gdzie $X \subset R$ i $A \in R$, oznacza:

$$X \rightarrow A_1, X \rightarrow A_2, ... X \rightarrow A_k$$
, gdzie { $A_1, A_2, ... A_k$ } = Y.

62. Co oznacza, że Y jest kluczem kandydującym dla danego schematu relacji o atrybutach tworzących zbiór X?

Odp.: Oznacza to, że Y \rightarrow Z dla dowolnego podzbioru Z zbioru atrybutów X. Jest tak dlatego, że gdy Y jest kluczem, to każda krotka ma inną wartość na atrybutach Y.

<u>Uwaga:</u> przyjmujemy, że klucz kandydujący jest kluczem minimalnym, tzn., że nie można z niego usunąć żadnego atrybutu bez utraty własności identyfikowania krotek.

63. Czy zależność funkcyjna jest własnością formalną? Uzasadnij.

Odp.: Zależność funkcyjna jest własnością semantyczną(!), a nie własnością formalną. Zależność funkcyjna jest odkrywana przez projektanta. Nie da się jej udowodnić. Można ją tylko uzasadnić właściwościami obszaru analizy.

Podobnie jest z innymi więzami integralności. Określenie dziedziny atrybutu, możliwość przyjmowania wartości pustej i jej interpretacja, określenie kluczy kandydujących i wybranie klucza głównego – to wszystko decyzje projektanta oparte na jego znajomości obszaru analizy.

64. Czy dla wszystkich relacji r(R) rozpiętych na tym schemacie mogą istnieć jakieś inne zależności funkcyjne (nie wskazane przez projektanta)?

Odp.: Zwykle tak. Można je wydedukować ze zbioru zależności F(zależności funkcyjne schematu R, które są semantycznie oczywiste) i pewnych reguł.

65. Czym jest domknięcie zbioru zależności funkcyjnych?

Odp.: Wszystkie zależności zbioru F i wszystkie zależności funkcyjne które można wydedukować ze zbioru F.

Domknięcie oznaczamy jako F ⁺.

66. Wymień reguły wnioskowania dla zależności funkcyjnych.

 $\mathbf{F} X \rightarrow X$ (zwrotność)

 $X \rightarrow Y + XZ \rightarrow YZ$ (powiększanie)

 $X \rightarrow Y, Y \rightarrow Z + X \rightarrow Z$ (przechodniość)

 $X \rightarrow YZ + X \rightarrow Y$ (dekompozycja)

 $X \rightarrow Y$, $X \rightarrow Z + X \rightarrow YZ$ (sumowanie)

 $X \rightarrow Y$, $WY \rightarrow Z + WX \rightarrow Z$ (pseudoprzechodniość)

gdzie napis PQ oznacza dla atrybutów {P, Q} a dla zbiorów atrybutów P U Q, oraz F jest znakiem inferencji.

67. Czym są reguły wnioskowania Armstronga (lub aksomaty Armstronga)?

Odp.: Są to pierwsze trzy reguły wnioskowania dla zależności fukcjyjnych, czyli zwrotność, powiększanie i przechodniość.

68. Jaką własność posiadają reguły wnioskowania Armstronga?

Odp.: Można z nich wyprowadzić pozostałe reguły, ale nie można usunąć żadnej z nich, bo stracą tę własność.

69. W jaki sposób można uzyskać domknięcie zbioru zależności F stosując reguły Armstronga? Odp.: Poprzez domknięcie każdego zbioru X (stojącego po lewej stronie zależności funkcyjnej) względem zbioru zależności F.

70. Kiedy dwa zbiory zależności funkcyjnych E i F są równoważne?

Odp.: Wtedy i tylko wtedy, gdy $E^+ = F^+$

71. Przez co realizujemy proces normalizacji?

Odp.: Proces normalizacji realizujemy przez dekompozycję schematów relacji.

72. Co musi brać pod uwagę proces normalizacji?

Odp.: Proces ten musi brać pod uwagę właściwość złączenia bezstratnego i właściwość zachowania zależności. Ta druga może być niekiedy pomijana.

73. Czym jest podstawowy atrybut relacji?

Odp.: Atrybut relacji nazywamy podstawowym (prymarnym), gdy należy do któregokolwiek klucza kandydującego. Gdy nie należy do żadnego klucza, to nazywamy go nieprymarnym.

74. Jakie są cechy 1NF (pierwsza postać normalna)?

Odp.: Każdy schemat relacji musi posiadać klucz główny.

Dziedzina każdego atrybutu musi zawierać wyłącznie wartości niepodzielne (atomowe), a wartość każdego atrybutu krotki musi być pojedynczą wartością z dziedziny.

75. Jakie są cechy 2NF?

Odp.: Schemat jest w 1NF i żaden nieprymarny atrybut nie jest częściowo zależny od dowolnego klucza. Mówimy krótko, że w tej postaci nie występują zależności częściowe. Rozkład schematu do 2NF polega na pozbyciu się zależności częściowych.

76. Jakie są cechy 3NF?

Odp.: Zależność $X \to A$ jest nazywana nietrywialną, gdy A nie jest elementem zbioru X. Schemat jest w 2NF i dla każdej nietrywialnej zależności $X \to A$ albo X jest nadkluczem albo A jest prymarny.

Innymi słowy, żaden nieprymarny atrybut nie jest przechodnio zależny od klucza. Rozkład schematu do 3NF polega na pozbyciu się zależności przechodnich.

77. Jakie są cechy BCNF?

Odp.: Jest to silniejsza wersja 3NF. Wymaga się, by dla każdej nietrywialnej zależności $X \to A$ zbiór atrybutów X był nadkluczem.

78. Co powinno cechować rozkłady schematów?

Odp.: Rozkłady powinny zachowywać zależności oraz pozwalać na złączenie nieaddytywne (odwracalność).

79. Kiedy rozkład zachowuje zależności?

Odp.: Gdy zbiór zależności w podschematach jest równoważny początkowemu zbiorowi zależności.

80. Kiedy rozkład jest odwracalny?

Odp.: Gdy każda relacja rozpięta na tym schemacie jest złączeniem naturalnym swoich rzutów na podschematy.

81. Kiedy powstają zależności wielowartościowe?

Odp.: Wtedy, gdy encje danego typu posiadają dwa niezależne atrybuty wielowartościowe. Np. student zna kilka języków obcych i kilka języków programowania. W odpowiedniej relacji musi wtedy wystąpić wiele krotek dla każdego studenta i muszą być powtarzane wszystkie wartości jednego atrybutu dla każdej wartości drugiego:

Adam Abacki; rosyjski; C++ Adam Abacki; rosyjski; Java Adam Abacki; rosyjski; SQL Adam Abacki; angielski; C++ Adam Abacki; angielski; Java Adam Abacki; angielski; SQL

Mówiąc nieformalnie zależność wielowartościowa pojawia się zwykle wtedy, gdy w ramach jednego schematu połączymy dwa atrybuty wielowartościowe jednego typu encji, albo dwa związki. Np. tabelę przedstawioną wyżej można skojarzyć ze strukturą encji typu STUDENT o dwóch atrybutach wielowartościowych: JĘZYK_NATURALNY, JĘZYK_ PROGRAMOWANIA. Tę samą strukturę informacji można przedstawić jako dwa związki wychodzące

z encji typu STUDENT: związek z encjami JĘZYK_NATURALNY i związek z encjami JĘZYK_PROGRAMOWANIA. Zauważmy, że prawidłowo wykonane mapowanie dla obu podanych struktur nie doprowadzi do omawianej tabeli z zależnością wielowartościową.

82. Definicja zależności wielowartościowej.

Odp.:

Między zbiorami atrybutów X, Y schematu R zachodzi zależność wielowartościowa X — >> Y wtw gdy dla każdej relacji r rozpiętej na R zachodzi:

jeżeli w r istnieją krotki t₁ i t₂ takie że t₁[X]=t₂[X] to istnieją również krotki t₃ i t₄ takie że:

- $\cdot t_1[X]=t_2[X]=t_3[X]=t_4[X]$
- $\cdot t_1[Y]=t_3[Y] \text{ oraz } t_2[Y]=t_4[Y]$
- $\cdot t_{2}[Z]=t_{3}[Z] \text{ oraz } t_{1}[Z]=t_{4}[Z]$

gdzie Z=R – (XUY).

Kiedy w R zachodzi X —⟩⟩ Y to również zachodzi X —⟩⟩ Z.

- 83. Kiedy zależność wielowartościową X ⟩ Y nazywamy trywialną? Odp.: Gdy Y⊂X lub R=XUY.
- 84. Podaj reguły dla zależności wielowartościowych.

Odp.:

(1)
$$X \longrightarrow Y \vdash X \longrightarrow (R-XY)$$
 (uzupełnianie)

(2)
$$X \longrightarrow Y$$
, $W \lor Z + WX \longrightarrow YZ$ (zwiększanie)

(3)
$$X \longrightarrow Y$$
, $Y \longrightarrow Z \vdash X \longrightarrow (Z-Y)$ (przechodniość)

gdzie X, Y, Z, W to zbiory atrybutów z $R(A_1, A_2, ... A_n)$,

napis PQ oznacza dla atrybutów {P, Q} a dla zbiorów atrybutów P U Q, oraz F jest znakiem inferencji.

85. Podaj reguły dla zależności funkcyjnych i wielowartościowych.

Odp.:

(4)
$$X \rightarrow Y + X \longrightarrow Y$$
 (replikacja)

(5) X —)) Y oraz istnieje W taki że W \cap Y= \emptyset , W \rightarrow Z, Y \supset Z

 $+ X \rightarrow Z$ (scalanie)

86. Co stanowi minimalny i zupełny zbiór reguł wnioskowania dla zależności obu typów (funkcyjnych i wielowartościowych)?

Odp.: Reguly Armstronga, reguly (1)-(3) oraz reguly (4) i (5).

Używając tych reguł można zbudować domknięcie dowolnego zbioru zależności obu typów.

87. Kiedy schemat znajduje się w 4NF?

Odp.: Schemat relacji R ze zbiorem F zależności funkcyjnych i zależności wielowartościowych znajduje się w czwartej postaci normalnej gdy dla każdej nietrywialnej zależności X — $\rangle\rangle$ Y w domknieciu F⁺ zbiór X jest nadkluczem.

R(A, B, C, D, E); AB — $\rangle\rangle$ C wtedy na podstawie (1) mamy AB — $\rangle\rangle$ DE (obie zależności są nietrywialne) rozkładamy schemat: R₁(A, B, C); AB — $\rangle\rangle$ C i R₂(A, B, D, E); AB — $\rangle\rangle$ DE.

88. Kiedy występuje zależność złączeniowa?

Odp.: Gdy schemat jest już w 4NF oraz istnieje odwracalny rozkład na trzy lub więcej podschematów.

89. Kiedy schemat jest w 5NF?

Odp.: Gdy dla każdej nietrywialnej zależności złączeniowej każdy podschemat wynikający z tej zależności zbudowany jest z atrybutów stanowiących nadklucz klucza schematu.

90. Czym jest DKNF?

Odp.: Jest to ostateczna postać normalna, która uwzględnia wszystkie rodzaje zależności i więzów.

91. Kiedy schemat jest w DKNF?

Odp.: Gdy wszystkie więzy i zależności, które powinny być zachowane w każdej relacji rozpiętej na tym schemacie, mogą być wymuszane przez więzy domenowe i więzy kluczy (kluczy głównych i kluczy obcych).

Wymuszenie ogólnych więzów integralności (np., że średnia płaca pracownika danej jednostki nie może być mniejsza od połowy płacy kierownika tej jednostki) przez domeny i klucze może być niewykonalne. Zwykle konieczne jest zdefiniowanie odpowiedniej procedury, asercji czy triggera.

92. Na czym polega sterowanie współbieżnością?

Odp.: Jest to proces zapewniający możliwość przetwarzania opartego na współistnieniu wielu procesów operujących na wspólnych (współdzielonych) danych w SZBD.

93. Czym jest transakcja?

Odp.: Transakcją nazywamy grupę instrukcji, które muszą być wykonane, aby odpowiednie zmiany zostały zapisane w bazie. Jeżeli chociaż jedna instrukcja z takiej grupy zakończy się niepowodzeniem, wówczas działanie wszystkich jest odwoływane.

BEGIN TRANSACTION – rozpoczęcie transakcji

COMMIT – zakończenie transakcji z zaakceptowaniem wszystkich zmian

ROLLBACK – zakończenie transakcji z wycofaniem wszystkich zmian

ROLLBACK TO SAVEPOINT – NazwaPunktuZapisu – zakończenie transakcji z wycofaniem wszystkich tych zmian, które nastąpiły od zdefiniowanego (w czasie działania transakcji) punktu zapisu NazwaPunktuZapisu.

94. Rozwiń skrót ACID (właściwości jakie powinna spełniać transakcja)

Odp.:

- niepodzielność (Atomicity)
- spójność (Consistency)
- izolacja (Isolation)
- trwałość (Durability)

95. Na czym polega atomowość transakcji?

Odp.: Atomowość to niepodzielność transakcji: albo wszystkie modyfikacje danych zakończą się sukcesem, albo żadna modyfikacja nie nastąpi. Zatem, jeżeli z jakiegoś powodu transakcja nie może być zakończona, to tzw. mechanizm odtwarzania musi zapewnić wycofanie wszystkich zmian wprowadzonych już przez tę transakcję w bazie danych.

96. Na czym polega spójność transakcji?

Odp.: Spojność oznacza, że po zakończeniu transakcji baza musi być w stanie spójnym, tj. muszą być zachowane wszystkie więzy integralności, a wewnętrzne struktury bazy (np. indeksy) powinny być doprowadzone do prawidłowego stanu.

97. Czym jest własność izolacji transakcji?

Odp.: Własność izolacji mówi, że modyfikacje przeprowadzane przez daną transakcję muszą być odizolowane od innych działających transakcji, nie może kolidować ze współbieżnym wykonywaniem innych transakcji.

98. Na czym polega trwałość transakcji?

Odp.: Po zakończeniu transakcji jej efekty muszą pozostać w bazie na stałe. Nie mogą zostać utracone w wyniku jakiejkolwiek awarii.

99. Jakie mogą wystąpić problemy z transakcjami?

Odp.:

- Problem utraconej modyfikacji (lost updates) nadpisanie modyfikacji
- Problem czytania brudnopisu (dirty read): Transakcja A odczytuje w czasie t4 wartość zmodyfikowaną wcześniej (w czasie t2) przez inną transkację jeszcze nie zatwierdzoną. W momencie cofnięcia transakcji B odczyt w czasie t4 staje się fałszywy.
- Problem niespójnej analizy (non-repeatable read): Transakcja A sumuje salda 3 rachunków (r1, r2, r3) o wartościach w czasie t1: 200 zł, 300 zł i 4000 zł.
 Równolegle transakcja B wykonuje przelew 1000 zł z rachunku r3 na r1.
 Gdyby A wykonać ponownie w czasie t10-t12 to wynik byłby inny.
- Wiersze widma (phantom reads): Transakcja A odczytuje rekordy, które spełniają pewne kryterium wyboru. Druga transakcja (B) wstawia nowe rekordy do tej samej tabeli, przy czym niektóre z nich spełniają kryterium sprawdzane przez A.
 Transakcja B może również modyfikować wiersze w taki sposób, że dodatkowe rekordy zaczną spełniać to kryterium. Mogą zatem pojawić się takie rekordy (fantomy), które spełniają dane kryterium, a które nie zostały odczytane przez A.

100. Jakie są typy blokad?

Odp.:

- blokady wyłączne (typu X, blokady do zapisu)
- blokady wspólne (typu S, blokady do odczytu)
- 1. Jeśli transakcja założy blokadę X na krotkę p, to próba założenia jakiejkolwiek blokady przez inną transakcję na tej samej krotce zostanie oddalona.
- 2. Jeśli transakcja A założy blokadę S na krotkę p, to:
- próba założenia blokady X przez transakcję B na tej samej krotce zostanie oddalona,
- próba założenia blokady S przez transakcję B na tej samej krotce zostanie zaakceptowana, czyli obie transakcje będą blokować p.
- 101. Podaj przykładowy protokół dostępu do danych.

Odp.:

- 1. Transakcja, która chce uzyskać dostęp do krotki, musi najpierw uzyskać blokadę S na tej krotce.
- 2. Transakcja, która chce modyfikować krotkę, musi najpierw uzyskać blokadę X na tej krotce. Jeśli transakcja wcześniej założyła blokadę S, to musi ona zwiększyć poziom blokady z S do X.
- 3. Jeżeli żądanie blokady od transakcji B zostanie odrzucone ze względu na to, że jest w konflikcie z blokadą założoną wcześniej przez transakcję A, to B przechodzi w stan oczekiwania aż ta blokada zostanie zdjęta (system powinien dbać o to, by transakcja B nie czekała w nieskończoność, tj. by nie nastąpiło zagłodzenie).
- 4. Blokady S i X są utrzymywane do końca działania transakcji (tj. do polecenia COMMIT lub ROLLBACK).
- 102. Czym jest zakleszczenie?

Odp.: Zakleszczenie to sytuacja, w której dwie lub więcej transakcji oczekuje na zwolnienie "wzajemnej" blokady.

103. Podaj strategie rozwiązywania zakleszczeń.

Odp.:

- 1. cofnąć losowo wybraną transakcję
- 2. cofnąć transkację, które najdłużej trwa
- 3. cofnąć najkrócej trwającą transakcję
- 104. Na czym polega Protokół dwufazowego blokowania (2 Phase Locking)?

Odp.:

- 1.Zanim transakcja rozpocznie działanie na pewnym obiekcie w bazie danych, musi założyć na ten obiekt blokadę.
- 2. Po zwolnieniu blokady transakcja nie może zakładać żadnej nowej blokady na jakimkolwiek obiekcie.
- 105. Podaj twierdzenie związane z protokołem dwufazowego blokowania.

Odp.: Jeśli wszystkie transakcje spełniają protokół dwufazowego blokowania, to wszystkie przeplatane porządki (współbieżne) są szeregowalne (poprawne).

106. Zdefiniuj domknięcie F⁺ zbioru zależności funkcyjnych F?

Odp.: Domknięcie F⁺ to zbiór zależności pierwotnych (tworzących zbiór F) oraz zależności, które można wywniosować z tamtych. Każda taka nowa zależność musi mieć tę własność, że będzie spełniona dla każdego zbioru danych spełniającego zależności ze zbioru F.

107. Jak zbudować F⁺?

Odp.: W 1974 W. Armstrong wykazał, że minimalnym zbiorem reguł wnioskowania potrzebnych do zbudowania domknięcia jest zbiór złożony z reguły zwrotności (R1), reguły zwiększania (R2) i reguły przechodniości (R3). W literaturze są one zwane aksjomatami Armstronga. W praktyce używa się również wtórej reguły: reguły dekompozycji (R4).

Systematyczny sposób budowania domknięcia F+ zbioru zależności funkcyjnych F polega na tym, że dla każdej zależności funkcyjnej $X \rightarrow Y$ tworzy się $X \rightarrow X^+$ gdzie X^+ to domknięcie zbioru X względem zbioru zalezności F. Wszystkie utworzone w ten sposób zależności $X \rightarrow X^+$ tworzą domnknięcie F^+ .

Należy tu pamiętać, że w teorii relacyjnych baz danych litery występujące po prawej i po lewej stronie zależności funkcyjnej mogą oznaczać dowolny atrybut bądź zbiór atrybutów.

108. Podaj algorytm obliczania domknięcia.

```
Odp.:

X^+ := X

repeat

old X^+ := X^+

for each (zależność funkcyjna Y \rightarrow Z w F) do

if old X^+ \supset Y then old X + := X^+ \cup Z;

until (X^+ = Old X^+);
```

109. Czym są indeksy?

Odp.: Indeksy to struktury używane w celu przyspieszenia dostępu do rekordów zapamiętanych w plikach bazy danych. Indeksy działają w oparciu o pola indeksujące, przy czym dla danego pliku można utworzyć różne indeksy (indeksy oparte na różnych polach). Pola indeksujące nazywamy również kluczami indeksowania (nie mylić z kluczem relacji!).

110. Podziały indeksów.

Odp.:

Podział pierwszy:

- podstawowe (primary index, indeks główny, założony na atrybucie porządkującym unikatowym),
- klastrowania (clustering index, na atrybucie porządkującym nieunikatowym)
- wtórne (secondary index, indeks drugorzędny, założony na atrybucie nieporządkującym).

Podział drugi:

- geste (wpis dla każdej wartości klucza, tj. dla każdego rekordu pliku danych)
- rzadkie (wpisy tylko dla niektórych wartości klucza)

Podział trzeci:

- jednopoziomowe
- dwupoziomowe
- wielopoziomowe
 - o B-drzewa w różnych odmianach, m.in.:
 - B⁺-drzewa
 - B -drzewa

111. Czym jest indeks główny?

Odp.: Indeks główny to uporządkowany plik rekordów. Jest on tworzony dla uporządkowanego pliku rekordów danych na polu stanowiącym klucz relacji. Każdy rekord indeksu składa się z dwóch pól stałej wielkości. Pierwsze ma taki typ jak pole klucza uporządkowania w pliku danych, drugie jest wskaźnikiem na blok dyskowy. Wartość pierwszego pola to wartość pola klucza pierwszego rekordu bloku danych wskazywanego przez wskaźnik. Na każdy rekord indeksu głównego przypada jeden blok danych, zatem liczba wpisów w indeksie równa się liczbie bloków danych zajmowanych przez plik indeksowany.

112. Czym jest indeks klastrowania?

Jest to indeks rzadki.

Odp.: Indeks klastrowania tworzymy dla pliku rekordów posortowanych według pola, którego wartości nie są unikatowe. Indeks ten jest także plikiem posortowanym. Każdy wpis zawiera odrębną wartość pola indeksującego i wskaźnik na pierwszy blok danych, który zawiera rekord o danej wartości pola indeksującego.

<u>Uwaga:</u> kilka kolejnych wskaźników indeksu może wskazywać ten sam blok oraz nie wszystkie bloki pliku danych muszą być wskazane w indeksie.

113. Dwa sposoby na zbudowanie Indeksu drugorzędnego na polu zawierającym wartości powtarzające się.

Odp.:

- Stosowanie wielu wpisów dla powtarzających się wartości pola
- Stosowanie wpisów o zmiennej długości albo o wpisów ze wskaźnikiem na blok wskaźników.
- 114. Podaj definicję drzewa wyszukiwania.

Odp.: Drzewo wyszukiwania rzędu p to drzewo, którego każdy wierzchołek zawiera co najwyżej p-1 wartości wyszukiwania oraz p wskaźników na wierzchołek podrzędny (lub wskaźników zerowych). Z każdą wartością wyszukiwania związany jest wskaźnik na rekord lub wskaźnik na blok. Wierzchołki drzewa przechowywane są w blokach, więc dostęp do poszukiwanego rekordu wymaga dostępu do tylu bloków ile elementów ma odpowiednia ścieżka w drzewie.

Drzewo wyszukiwania nie jest zrównoważone.

115. Omów B-drzewa.

Odp.: Jest to cała rodzina struktur, które organizują przestrzeń na dysku w zrównoważoną drzewiastą strukturę bloków.

Z każdym B-drzewem jest związany parametr p, który wyznacza układ drzewa, a który dobierany jest tak, aby w jednym bloku zmieściło się p-1 par (wartość wyszukiwania, wskaźnik na blok) i p wskaźników drzewa. Dane te tworzą węzeł drzewa, przy czym wartości wyszukiwania są uporządkowane rosnąco. Wskaźnik drzewa kieruje nas do podrzewa zawierającego wartości wyszukiwania z przedziału ograniczonego dwoma wartościami wyszukiwania sąsiadującymi w węźle z takim wskaźnikiem (a w przpadkach skrajnych jedną wartością).

116. Cechy B⁺ -drzewa

Odp.: W B+-drzewach w węzłach wewnętrznych nie ma wskaźników na bloki danych, są tylko wskaźniki na bloki wierzchołków niższego poziomu drzewa. Wskaźniki na bloki danych występują dopiero w liściach. Ostatni wskaźnik liścia wskazuje na blok następnego liścia z prawej strony.

W korzeniu są co najmniej dwa wskaźniki na bloki niższych poziomów. W pozostałych węzłach jest co najmniej połowa liczby możliwych do zapisania tam wskaźników.

Przykład: blok ma 4096 B, klucz 4 B, wskaźnik 8 B. W takiej sytuacji szukamy największej wartości p, która spełnia nierówność $4(p-1)+8p \le 4096$. Jest to 341.

Zatem wierzchołek wewnętrzny może zawierać co najwyżej 340 kluczy i 341 wskaźników.

117. Pierwsza mediana Date'a.

Odp.:

Date proposed two different solutions for the median (Date 1992a; Celko and Date 1993). His first solution was based on the fact that if you duplicate every row in a table, the median will stay the same. The duplication will guarantee that you always work with a table that has an even number of rows. The first version that appeared in his column was wrong and drew some mail from me and from others who had different solutions. Here is a corrected version of his first solution:

```
CREATE VIEW Temp1
AS SELECT weight FROM Parts
   UNI ON ALL
   SELECT weight FROM Parts;
CREATE VIEW Temp 2
AS SELECT weight
     FROM Temp1
    WHERE (SELECT COUNT(*) FROM Parts)
           <= (SELECT COUNT(*)
                 FROM Temp1 AS T1
                 WHERE T1. weight >= Templ. weight)
      AND (SELECT COUNT(*) FROM Parts)
            <= (SELECT COUNT(*)
                  FROM Temp1 AS T2
                  WHERE T2. weight <= Temp1. weight);
SELECT AVG(DISTINCT weight) AS median
  FROM Temp 2;
```

This involves the construction of a doubled table of values, which can be expensive in terms of both time and storage space. The use of AVG(DI STI NCT x) is important, because leaving it out would return the simple average instead of the median. Consider the set of weights (12, 17, 17, 14, 12, 19). The doubled table, Temp1, is then (12, 12, 12, 12, 14, 14, 17, 17, 17, 17, 19, 19). But because of the duplicated values, Temp2 becomes (14, 14, 17, 17, 17, 17), not just (14, 17). The simple average is (96 / 6.0) = 16; it should be (31/2.0) = 15.5 instead.

118. Pierwsza mediana Celko.

Odp.:

A slight modification of Date's solution will avoid the use of a doubled table, but it depends on a CEI LI NG() function.

```
SELECT MIN(weight) -- smallest value in upper half
FROM Parts
WHERE weight
IN (SELECT P1. weight
FROM Parts AS P1, Parts AS P2
WHERE P2. weight >= P1. weight
GROUP BY P1. weight
HAVING COUNT(*)
```

every value is seen as a unique entity. Selecting the middle values is then a special case of finding the nth item in the table.

This method depends on being able to have a HAVI NG clause without a GROUP BY, which is part of the ANSI standard but often missed by new programmers.

Another handy trick, if you don't have FLOOR() and CEILING() functions, is to use (COUNT(*) + 1) / 2.0 and COUNT(*) / 2.0 + 1 to handle the odd-and-even-elements problem. Just to work it out, consider the case where the COUNT(*) returns 8 for an answer: (8 + 1) / 2.0 = (9 / 2.0) = 4.5 and (8 / 2.0) + 1 = 4 + 1 = 5.

The 4.5 will round to 4 in DB2 and other SQL implementations. The case where the COUNT(*) returns 9 would work like this: (9 + 1) / 2.0 = (10 / 2.0) = 5 and (9 / 2.0) + 1 = 4.5 + 1 = 5.5, which will likewise round to 5 in DB2.

119. Tabela krzyżowa.

Odp.

Czasami zachodzi potrzeba, aby dane wybierane przez kwerendę grupować według wartości zapisanych w dwóch lub więcej kolumnach tabeli źródłowej. Ponieważ dane grupowane w taki sposób przez kwerendę wybierającą są mało czytelne, do realizacji takiego zadania powinniśmy wykorzystać kwerendę krzyżową. Poniższe zestawienie zawiera porównanie analizy wartości miesięcznej sprzedaży generowanej przez pracowników.

Manustalia	Minaina Consolai	
Nazwisko	Miesiąc	Sprzedaż
Nowak	Styczeń	4543
Nowak	Luty	3865
Nowak	Marzec	4520
Kowalski	Styczeń	4230
Kowalski	Luty	3850
Kowalski	Marzec	4390

Nazwisko	Styczeń	Luty	Marzec
Nowak	4543	3865	4520
Kowalski	4230	3850	4390
KOWalski	4230	3830	4390

porównania sprzedaży pracowników poszczególnych miesiącach

Wynik kwerendy wybierającej nie ułatwia Kwerenda krzyżowa daje możliwość łatwego porównania wyników obu pracowników w poszczególnych| miesiącach