Bazy danych



andrzej.lachwa@uj.edu.pl

7/14

Zależności funkcyjne

Wszystkie atrybuty schematu relacyjnej bazy danych nazwiemy, w celu ułatwienia prezentacji pewnych problemów teoretycznych, <u>relacją uniwersalną schematu</u>.

$$R = \{A_1, A_2, ... A_n\}$$

Zależność funkcyjna to wiązanie integralności między atrybutami:

$$X \rightarrow A$$
, gdzie $X \subseteq R$ i $A \subseteq R$,

które oznacza, że dla dowolnych krotek t_1 i t_2 należących do relacji r(R): jeżeli $t_1[X]=t_2[X]$ to $t_1[A]=t_2[A]$.

Innymi słowy , wartości atrybutów tworzących zbiór X krotki t relacji r(R) jednoznacznie determinują wartość tej krotki dla atrybutu A.

Zależność funkcyjna jest własnością schematu R i ma być spełniona przez wszystkie relacje r(R) rozpięte na tym schemacie.

Dla uproszczenia zapisów przyjmujemy, że

$$X \rightarrow Y$$
, gdzie $X \subseteq R$, $A_i \subseteq R$, $\{A_{1'}, A_{2'}, \dots A_k\} = Y$

oznacza $X \to A_1$, $X \to A_2$, ... $X \to A_k$.

Dla danego schematu relacji o atrybutach tworzących zbiór X, jeżeli Y jest kluczem kandydującym (każda krotka ma inną niepustą wartość na atrybutach Y), to $Y \rightarrow Z$ dla dowolnego podzbioru Z zbioru atrybutów X.

<u>Uwaga</u>: przyjmujemy, że klucz kandydujący jest kluczem minimalnym, tzn., że nie można z niego usunąć żadnego atrybutu bez utraty własności identyfikowania krotek.

Zależność funkcyjna jest własnością semantyczną(!), a nie własnością formalną. Zależność funkcyjna jest odkrywana przez projektanta. Nie da się jej udowodnić. Można ją tylko uzasadnić właściwościami obszaru analizy.

Podobnie jest z innymi więzami integralności. Określenie dziedziny atrybutu, możliwość przyjmowania wartości pustej i jej interpretacja, określenie kluczy kandydujących i wybranie klucza głównego – to wszystko decyzje projektanta oparte na jego znajomości obszaru analizy.

Projektant określa zależności funkcyjne schematu *R*, które są semantycznie oczywiste. Niech będzie to zbiór zależności *F*.

Czy dla wszystkich relacji r(R) rozpiętych na tym schemacie mogą istnieć jakieś inne zależności funkcyjne (nie wskazane przez projektanta)?

Zwykle tak. Można je wydedukować ze zbioru zależności *F* i pewnych reguł.

Wszystkie zależności zbioru F i wszystkie zależności funkcyjne które można wydedukować ze zbioru F nazywamy domknięciem tego zbioru i oznaczamy F^+ .

Reguły wnioskowania dla zależności funkcyjnych

$$-X \rightarrow X$$
 (zwrotność)

$$X \rightarrow Y \vdash XZ \rightarrow YZ$$
 (powiększanie)

$$X \rightarrow Y$$
, $Y \rightarrow Z \vdash X \rightarrow Z$ (przechodniość)

$$X \rightarrow YZ \vdash X \rightarrow Y$$
 (dekompozycja)

$$X \rightarrow Y, X \rightarrow Z \vdash X \rightarrow YZ$$
 (sumowanie)

$$X \rightarrow Y$$
, $WY \rightarrow Z \vdash WX \rightarrow Z$ (pseudoprzechodniość)
gdzie napis PQ oznacza dla atrybutów $\{P, Q\}$ a dla zbiorów
atrybutów $P \cup Q$, oraz \vdash jest znakiem inferencji.

Pierwsze trzy reguły noszą nazwę <u>aksjomatów Armstronga</u>, albo (lepiej) <u>reguł wnioskowania Armstronga</u>.

Mają one tę własność, że można z nich wyprowadzić pozostałe reguły, ale nie można usunąć żadnej z nich, bo stracą tę własność.

Domknięcie zbioru zależności *F* można zatem uzyskać stosując do tych zależności reguły Armstronga. Robi się to zwykle poprzez domknięcie każdego zbioru *X* (stojącego po lewej stronie zależności funkcyjnej) względem zbioru zależności *F*.

Dwa zbiory zależności funkcyjnych E i F są równoważne wtw gdy $E^+ = F^+$.

Algorytm domknięcia zbioru X wględem F

```
X^+ := X;

repeat

oldX^+ := X^+;

for each zależność funkcyjna Y \rightarrow Z w F do

if X^+ \supset Y then X^+ := X^+ \cup Z;

until X^+ = oldX^+;
```

O minimalnych zbiorach zależności funkcyjnych zobacz: [Ramez Elmasri, Shamkant B. Navathe, str. 336]

Statystyki w języku SQL

W różnych produktach SQL spotkamy rozmaite funkcje wbudowane ułatwiające analizy statystyczne. Jeżeli nie zależy nam na przenośności kodu, to lepiej użyć funkcji wbudowanych.

Zacznijmy od najprostszych statystyk (dla bazy World):

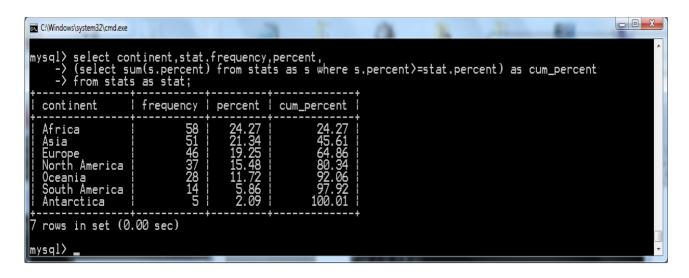
```
select c.continent, count(c.continent) as frequency,
       round(100.0*(count(c.continent))/
       (select count(*) from country),2) as percent
from country as c
group by continent;
create temporary table statistics as
   select c.continent, count(c.continent) frequency,
      round(100.0*(count(c.continent))/
      (select count(*) from country),2) as percent
   from country as c
   group by continent
   order by percent desc;
```

cm C:\Windows\system32\cmd.exe mysql> create ter -> select c> round(100 -> from coun: Query OK, 7 rows Records: 7 Dupl mysql> select * *	continent, co .0*(count(c.o try as c grou affected (0 icates: 0 Wa	ount(c.cont continent); up by conti .42 sec) arnings: 0	inent) frequency, /(select count(*) from country),2) as percent nent order by percent desc;
continent	frequency	percent	
Africa Asia Europe North America Oceania South America Antarctica	58 551 46 32 14 5	24.27 21.34 19.25 15.48 11.72 5.86 2.09	
7 rows in set (0 mysql>	.00 sec)	+	

select continent,stat.frequency,
 (select sum(s.frequency) from stats as s
 where s.frequency>=stat.frequency) as cumulative
from stats as stat;

mysql> select comes of select sum of the select	um(s.frequenc s as stat;	cy) from stats	as s where	s.frequen	cy>=stat.frequ	uency) as cu	mulative
continent	frequency	cumulative					
Africa Asia Europe North America Oceania South America Antarctica	58 51 46 37 28 14 5	58 109 155 192 220 234 239					
7 rows in set (0 mysql>	.00 sec)						4

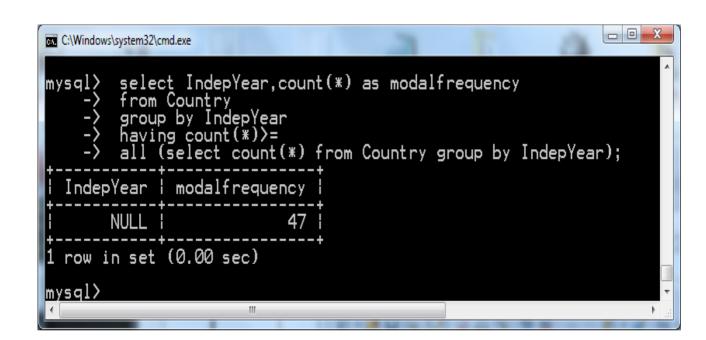
select continent, stat.frequency, percent,
 (select sum(s.percent) from stats as s
 where s.percent>=stat.percent) as cum_percent
from stats as stat;

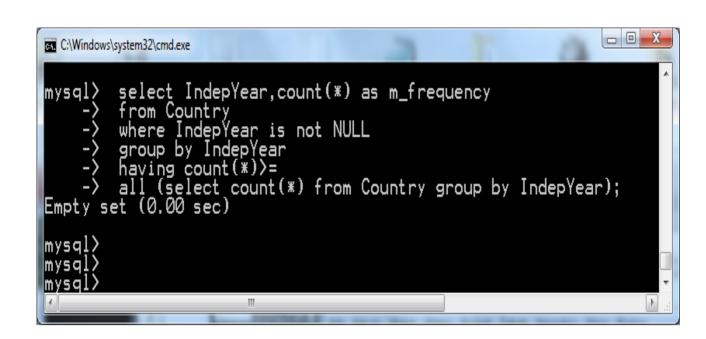


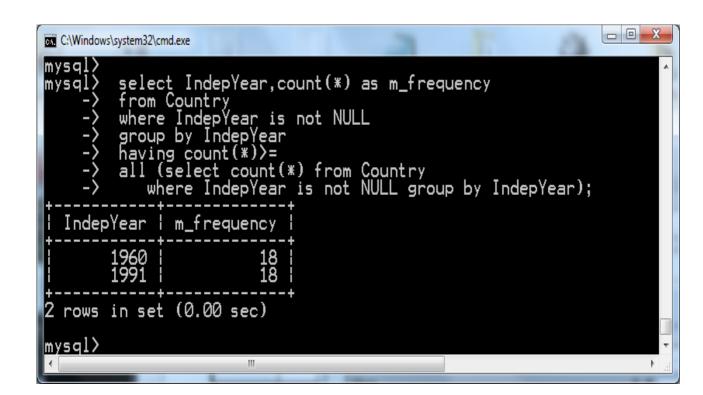
Wartość modalna

Wartość modalna to wartość najczęściej pojawiająca się w zbiorze (jeśli są takie dwie wartości, to mówimy że rozkład jest dwumodalny, podobnie trzymodalny etc.).

Wykonajmy to zapytanie w kilku krokach:







Wartość modalna jest słabą statystyką. Na przykład

1. gdy liczymy modalne pobory wśród pracowników, to dokładna wartość tej zmiennej nie jest dobra – lepiej dopuścić kilkuprocentowe odchylenie:

```
having count(*)>=
all (select count(*)*0.95 from ...
```

2. gdy dwie częstości są blisko siebie to dobrym rozwiązaniem jest dopuszczenie odchylenia *k* wartości

Wartość średnia

• AVG([DISTINCT] expr)

Returns the average value of *expr*. The DISTINCT option can be used to return the average of the distinct values of *expr*.

AVG () returns NULL if there were no matching rows.

```
mysql> SELECT student_name, AVG(test_score)
    -> FROM student
    -> GROUP BY student_name;
```

[MySQL 5.6 Reference Manual, p. 1372]

```
C:\Windows\system32\cmd.exe
mysql> select avg(indepYear) from Country;
  avg(indepYear)
       1847.2604
  row in set (0.01 sec)
mysql> select sum(indepYear)/count(*) from Country;
  sum(indepYear)/count(*)
                 1483.9916
  row in set (0.00 sec)
mysql>
              111
```

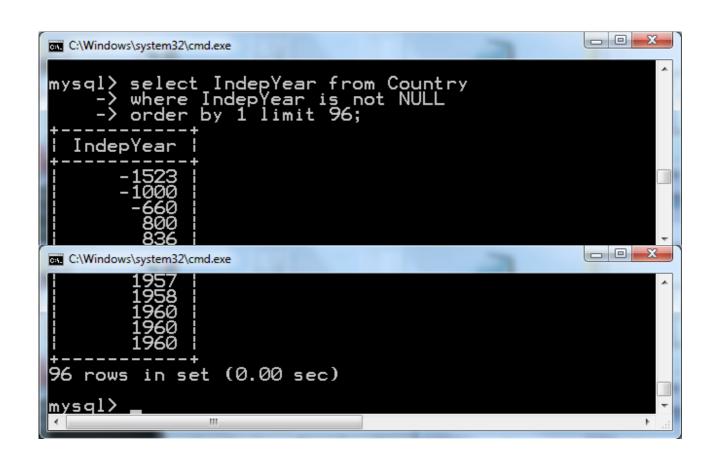
Mediana

Jest to wartość, dla której jest dokładnie tyle samo elementów o wartościach od niej niższych, co elementów o wartościach od niej wyższych. Jeśli taka wartość istnieje w zbiorze danych to nazywamy ją medianą statystyczną, jeżeli nie, to oblicza się medianę finansową. Zbiór danych dzieli się wtedy na dwa równoliczne, tak by elementy pierwszego były mniejsze od elementów drugiego, następnie oblicza się średnią między maksimum pierwszego i minimum drugiego.

Inne nazwy: wartość środkowa, wartość przeciętna.

Z medianą statystyczną jest problem, gdy wartości środkowych jest kilka (wskazany wyżej podział jest wówczas niemożliwy).

```
_ _ _ X
C:\Windows\system32\cmd.exe
mysql> select IndepYear from Country
-> where IndepYear is not NULL
-> order by 1;
   IndepYear
                                                                        _ 0 X
C:\Windows\system32\cmd.exe
192 rows in set (0.01 sec)
mysql>
```



```
- - X
C:\Windows\system32\cmd.exe
mysql> select count(*) from Country
-> where IndepYear is not NULL and
-> IndepYear>1960;
   count(*)
             81
1 row in set (0.00 sec)
mysql> select count(*) from Country
-> where IndepYear is not NULL and
-> IndepYear<1960;
   count(*)
             93
1 row in set (0.00 sec)
mysql> select count(*) from Country
-> where IndepYear is not NULL and
-> IndepYear=1960;
   count(*)
             18
1 row in set (0.00 sec)
mysql>
                 111
```

Kwartyle

Kwartyle dzielą wszystkie obserwacje na cztery równe co do ilości grupy .Kwartyl pierwszy (Q1) dzieli obserwacje w stosunku 25% do 75%, co oznacza, że 25% obserwacji jest niższa bądź równa wartości Q1, a 75% obserwacji jest równa bądź większa niż Q1.

Kwartyl drugi (Q2), inaczej zwany medianą(!), dzieli obserwacje na dwie części w stosunku 50% do 50%.

Kwartyl trzeci (Q3) dzieli obserwacje w stosunku 75% do 25%, co oznacza, że 75% obserwacji jest niższa bądź równa wartości Q3, a 25% obserwacji jest równa bądź większa niż Q3.

Odchylenie ćwiartkowe (Q), to połowa różnicy między trzecim a pierwszym kwartylem.

Kwantyle

Kwantylem rzędu p z przedziału (0,1) jest taka wartość x_p zmiennej losowej, że wartości $\leq x_p$ są przyjmowane z prawdopodobieństwem co najmniej p, a wartości $\geq x_p$ są przyjmowane z prawdopodobieństwem co najmniej 1-p.

Kwantyl rzędu ½ to inaczej mediana.

Kwantyle rzędu ¼, 2/4, 3/4 to kwartyle

Kwantyle rzędu ⅓,¾,⅓, ⅓ to kwintyle.

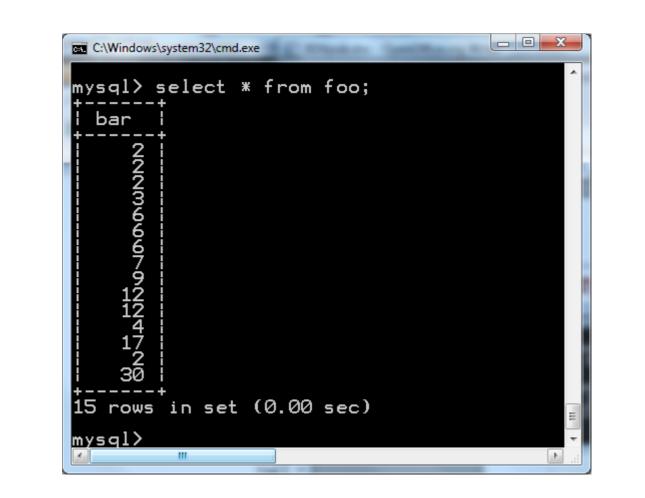
Kwantyle rzędu 1/10, 2/10, ... to decyle.

Przykład

```
mysql> create table foo(bar int);
Query OK, 0 rows affected (0.29 sec)

mysql> insert into foo(bar) values (2),(2),(2),(3),(6),(6),(6),(7),(9),(12),(12),(4),(17),(2),(30);
Query OK, 15 rows affected (0.01 sec)
Records: 15 Duplicates: 0 Warnings: 0

mysql> _______
```



Pierwsza mediana Date'a

```
mysql> create view foo1
-> as select bar from foo
-> union all
-> select bar from foo;
Query OK, Ø rows affected (0.07 sec)

mysql>
```

- 2 2 2 3 6 6 6 7 9 12 12 4 17 2 30
- 2 2 2 2 3 4 6 <u>6</u> 6 7 9 12 12 17 30

```
C:\Windows\system32\cmd.exe
mysql> create view foo2
        as select bar from foo1
         where
        (select count(*) from foo)<=
         (select count(*) from foo1 as f1 where f1.bar>=foo1.bar)
         and
-> (select count(*) from foo)<=
-> (select count(*) from foo1 as f2 where f2.bar<=foo1.bar);
Query OK, Ø rows affected (0.10 sec)
mysql>
```

```
- - X
C:\Windows\system32\cmd.exe
mysql> select * from foo2;
  bar
6 rows in set (0.02 sec)
mysql> select avg(distinct bar) as median
-> from foo2;
  median
  6.0000
1 row in set (0.02 sec)
mysql>
```

```
- 0 X
C:\Windows\system32\cmd.exe
Query OK, 4 rows affected (0.01 sec)
Records: 4 Duplicates: 0 Warnings: 0
mysal> drop view foo1;
Query OK, 0 rows affected (0.03 sec)
mysal> drop view foo2;
Query OK, 0 rows affected (0.04 sec)
mysal> create view foo1
    -> as select bar from foo
    -> union all
    -> select bar from foo;
Query OK. 0 rows affected (0.08 sec)
mysql> create view foo2
    -> as select bar from foo1
    -> where
    -> (select count(*) from foo)<=
    -> (select count(*) from fool as fl where fl.bar>=fool.bar)
    -> (select count(*) from foo)<=</pre>
    -> (select count(*) from foo1 as f2 where f2.bar<=foo1.bar);</p>
Query OK. 0 rows affected (0.41 sec)
mysql> select avg(distinct bar) as median
    -> from foo2:
 median
 7.0000
1 row in set (0.02 sec)
mysal>
```

2 2 2 2 3 4 6 6 6 <u>7</u> 9 12 12 17 30 30 130 104 105

a teraz dodam 4 i powinno być

2 2 2 2 3 4 4 6 6 <u>6 7</u> 9 12 12 17 30 30 130 104 105 6.5

skrypt.txt

```
insert into foo(bar) value (4);
drop view foo1;
drop view foo2;
create view foo1
  as select bar from foo
  union all
  select bar from foo;
create view foo2
  as select bar from foo1
  where
  (select count(*) from foo)<=
  (select count(*) from foo1 as f1 where f1.bar>=foo1.bar)
  and
  (select count(*) from foo)<=
  (select count(*) from foo1 as f2 where f2.bar<=foo1.bar);
select avg(distinct bar) as median
  from foo2;
```

```
- - X
C:\Windows\system32\cmd.exe
mysql> \. skrypt.txt
Query OK, 1 row affected (0.02 sec)
Query OK, 0 rows affected (0.04 sec)
Query OK, 0 rows affected (0.04 sec)
Query OK. 0 rows affected (0.09 sec)
Query OK, 0 rows affected (0.10 sec)
  median
  6.5000
1 row in set (0.02 sec)
mysql>
          -111
```

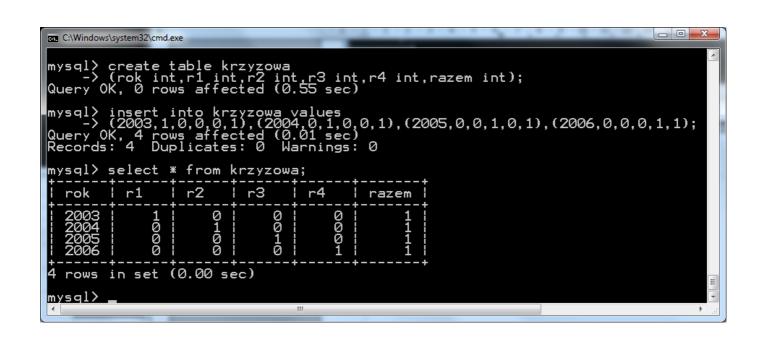
Pierwsza mediana Celko

Liczymy osobno najmniejszą wartość w górnej połowie i największą wartość w dolnej połowie.

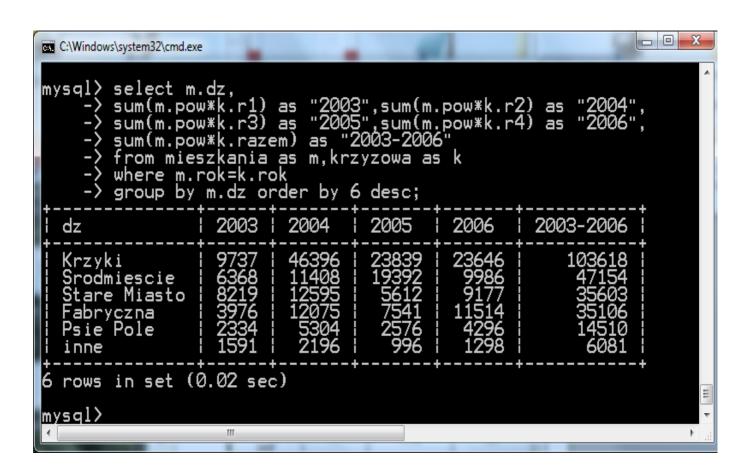
Operacja grupowania przebiega po wszystkich wierszach tabeli F1 i dlatego należy tabelę FOO uzupełnić o klucz ID:

Tabela krzyżowa

Tworzymy tabelę pomocniczą a następnie połączymy ją z tabelą danych sprzedaży z czterech lat od 2003 do 2006.



```
- - X
C:\Windows\system32\cmd.exe
mysql> load data infile 'i:/my_SQL/mieszk.csv' into table mieszkania
-> fields terminated by ';' optionally enclosed by '$'
-> lines terminated by '\r\n';
Query OK, 3700 rows affected (0.41 sec)
Records: 3700 Deleted: 0 Skipped: 0
                                                          Warnings: 0
mysql> select * from mieszkania limit 10;
   dz
                        rok
                                   cena
                                                  POW
                                                      69
70
   Krzyki
   Fabryczna
    abryczna
   Srodmiescie
10 rows in set (0.00 sec)
mysql>
```



Ćwiczenie:

Wygeneruj wypłaty dla kilku bankomatów dla jednego miesiąca i wykonaj dla takich danych tabelę krzyżową.